



# Ökonometria

Beadandó feladat

Granát Marcell - AYCOPF

2021. január 2.

## Tartalomjegyzék

<b>Bevezetés</b>	<b>2</b>
<b>Elméleti megfontolás</b>	<b>2</b>
<b>Modellbecslés és hipotézis vizsgálat</b>	<b>2</b>
Becsült előjelek értelmezése . . . . .	2
Szignifikancia értelmezése . . . . .	3
Együtthatók összegére tett előzetes feltevés ellenőrzése . . . . .	3
<b>Átlagos kiadási rugalmasságok</b>	<b>5</b>
<b>A modell bővítése</b>	<b>6</b>
<b>R kódok</b>	<b>9</b>

## Bevezetés

Ay alábbi rövid kézirat a brit **Family Expenditure Survey** adataiból kinyert fogyasztási jellemzőket tárgyalja. Az empirikus elemzés egyszerű lineáris regresszió alkalmazásával készül. Az adatok összesen 1519 család jövedelmét és kiadását tartalmazza, továbbá 6 termékcsoport (alkohol, ruházkodás, nem alkoholtartalmú élelmiszer, fűtés, közlekedés, egyéb) fogyasztáson belüli részarányát. Dolgozatom során én kizárólag az egy gyermekes családokra szűkíttem az elemzést<sup>1</sup>.

## Elméleti megfontolás

Miután az egyes termékek fogyasztáson belüli aránya adott, így egy egyszerű lineáris regresszióban magyarázóváltozónak választva a fogyasztási kiadás logaritmusát jól interpretálható eredményeket kapunk. Ebben a felírásban (1. egyenlet)  $\gamma_j$  értelmezése az alábbi: a fogyasztás 1%-kal magasabb értéke mellett c.p. várhatóan hány % $P$ -al változik meg  $j$ -edik termékcsoportra fordított kiadás teljes fogyasztáson belüli megoszlása.

$$w_j = \beta_j + \gamma_j \log(\text{cons}) + u_j, \quad j = 1, 2, \dots, 6 \quad (1)$$

Miután az egyes termékcsoportokra fordított kiadások arányainak összegének 1-nek kell lennie és a hibatagok várható értéke 0, így az 1. egyenlet alapján adódik a következő összefüggés:

$$\begin{aligned} \sum_{j=1}^6 w_j &= 1 \\ \sum_{j=1}^6 \beta_j + \gamma_j \log(\text{cons}) &= 1 \end{aligned} \quad (2)$$

A 2. egyenletben  $\beta_j$ -k összege jelenít meg egy fogyasztás szintjétől független komponenst, míg a  $w_j$  becslült értékek egymáshoz viszonyított mértéke a fogyasztás függvényeként tud változni. Annak érdekében, hogy a fogyasztás nagyságának minden értéke mellett biztosítva legyen, hogy  $\sum w_j = 1$ , szükséges megkötés tehát, hogy a fogyasztás logaritmusához rendelt együtthatók összege 0 legyen, ezáltal pedig adódik, hogy a 6 termékre becslült egyenletekben szereplő konstansok összege 1 legyen.

$$\begin{aligned} \sum \gamma_j \log(\text{cons}) &= 0 \\ \sum \beta_j &= 1 \end{aligned} \quad (3)$$

Mivel az egyes  $\gamma_j$  együttható megadják tehát, hogy a  $j$ -edik termék kereslete nő vagy csökken-e a fogyasztás növekedésével, így amennyiben a becslült együttható értéke 0 alatti (feletti), úgy a  $j$ -edik termékcsoportra költött összeg várhatóan nagyobb hányadát teszi ki a teljes fogyasztásnak, ha a fogyasztás szintje alacsonyabb (magasabb).

## Modellbecslés és hipotézis vizsgálat

### Becslült előjelek értelmezése


Az 1. egyenlet által leírt lineáris regresszió modellekben szereplő  $\gamma_j$  együtthatókat ismerteti az 1. ábra. Az ábráról leolvasható, hogy csökken a fogyasztáson belüli aránya az élelmiszernek és a fűtésnek, míg az alkohol,

<sup>1</sup>Feladatkiírás által előírt megkötés.

a közlekedés, a ruházkodás és az egyéb termékcsoportba tartozó javak aránya növekszik. Ez az eredmény összhangban van azzal, amit empirikus vizsgálat nélkül mondanánk, ugyanis élelmiszerre és fűtésre mindenkor szükséges egy bizonyos összeget kiadni. Az alkohol fogyasztás és a ruházkodás szükségesség esetén visszaszorítható, a közlekedésnek is könnyen található olcsóbb alternatívája.

## Szignifikancia értelmezése

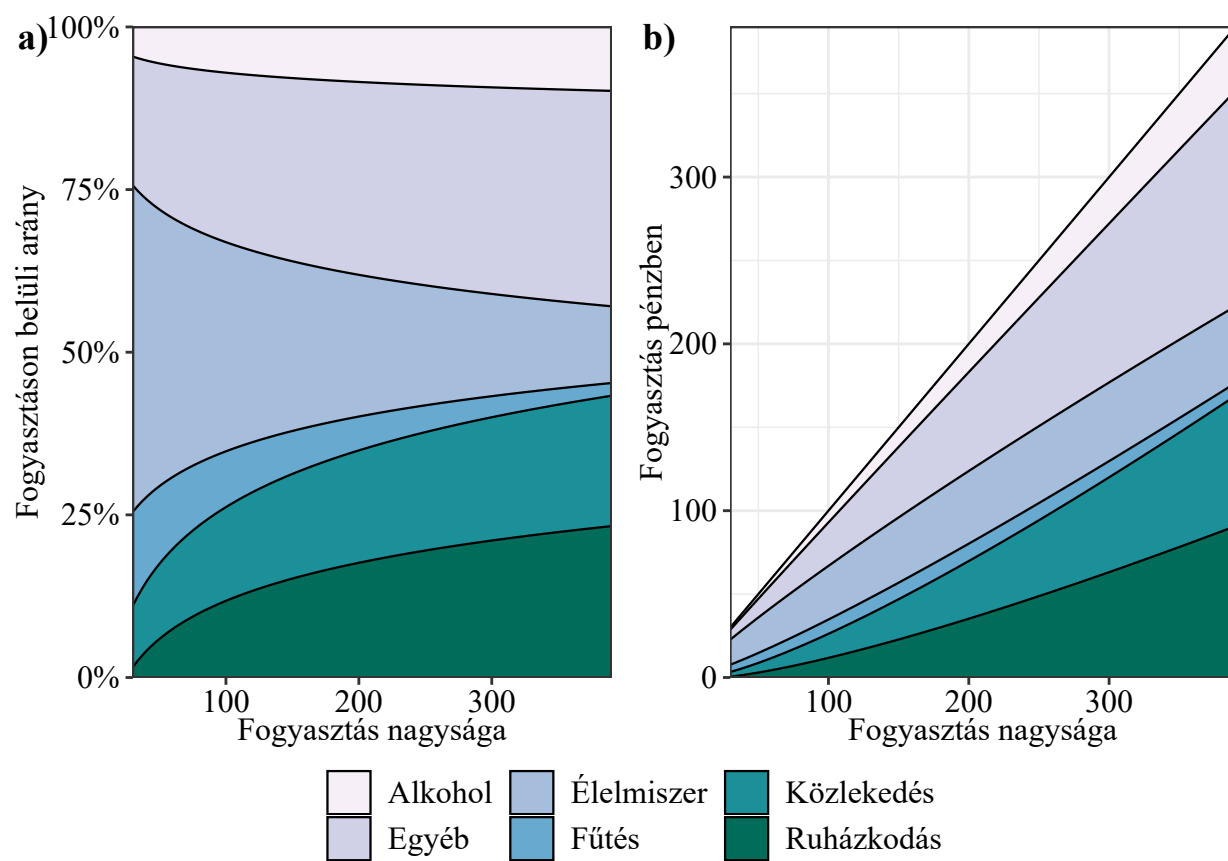
**Statisztikai értelemben valamennyi meredekségi együttható szignifikánsnak bizonyult** (belátható ez abból is, hogy a paraméterbecslésekhez tartozó 95%-os konfidencia intervallumok egyikse sem tartalmazza a zérust), az empirikus szignifikanciaszint mindössze némely tengelymetszet esetében nem különbözik szignifikánsan 0-tól. Közgazdasági értelemben vett szignifikancia (a becsült hatások kellően nagyok-e ahhoz, hogy figyelmet fordítsunk rá) értelmezéséhez a 2. ábra szolgáltat információt. A két diagram vízszintes tengelyén látható a mintában szereplő fogyasztási értékek intervalluma, az a) panel függőleges tengelyén a termékcsoportok fogyasztáson belüli megoszlásának modellbecslése, míg a b) panelen az egyes termékcsoportokra fordított kiadás pénzben (szintén modellbecslés). A diagramokból kivehető, hogy ezen becsült paraméterek mentén jelentős átrendeződés van a termékekre fordított kiadások arányai között, amíg a legkisebb kiadástól a legnagyobbig eljutunk. Az egyetlen viszonylag állandó fogyasztási aránnyal rendelkező terméktípus az alkohol. Ennek oka lehet, hogy az alkohol fogyasztás fogyasztási hányada nem lineáris függvénye a fogyasztás szintjének, ahogyan ezt a 3. ábra megvilágítja. Mind a kiemelten alacsony, mind a kiemelten magas fogyasztással rendelkező háztartások esetében alacsonyabb az alkoholra fordított kiadások aránya, mint a nem szélsőséges eseteknél. Előbbiek esetében valószínűleg nincs meg a forrás, amit szeszes italokra költenének, így vagy kevesebbet, vagy olcsóbb termékeket vásárolnak, míg utóbbiak esetében valószínűleg a kiemelkedő szocio-ökonómiai háttér folytán alacsonyabb a fogyasztás.



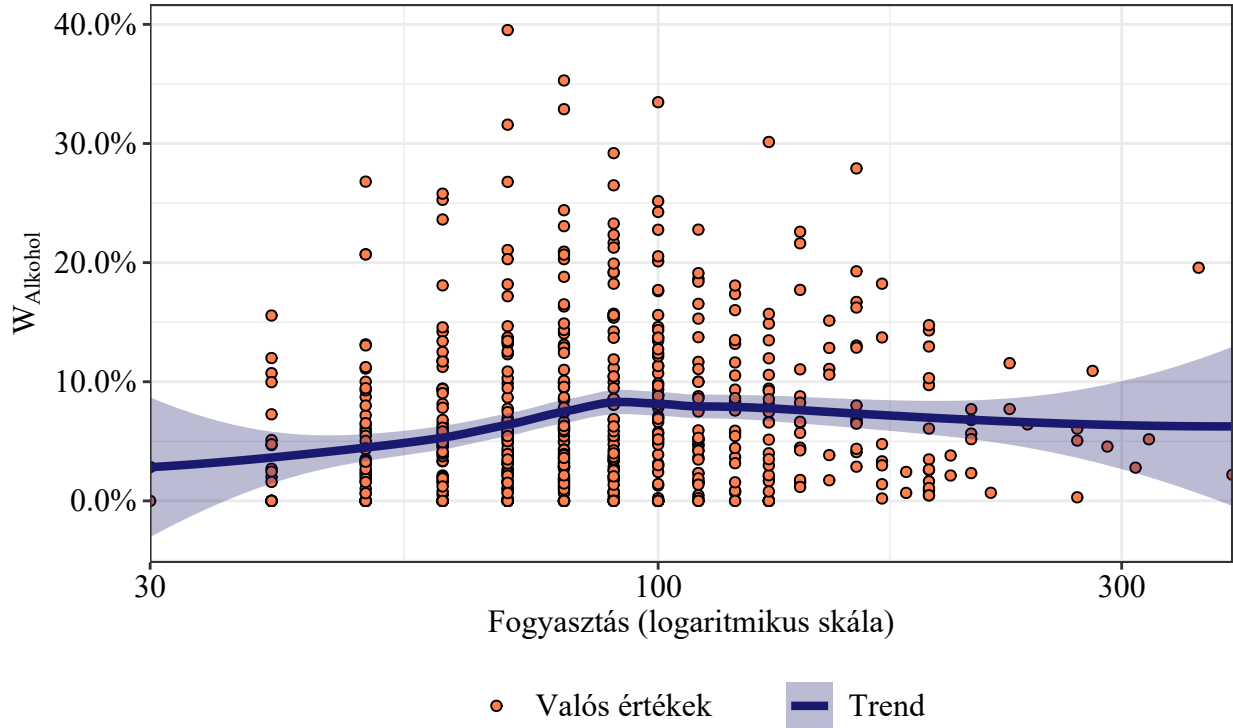
1. ábra. Termékcsoportonként becsült  $\gamma$  koefficiens

## Együtthatók összegére tett előzetes feltevés ellenőrzése

A paraméterbecslések között fennálló algebrai kapcsolatot az alábbi módon ellenőrzöm: (1) Regresszió becslése, melyben eredményváltozó, hogy egy  $j$ -edik terméknek mekkora a megoszlása a fogyasztáson belül, magyarázó változó pedig, hogy mely termékcsoportról van szó (egyszerű dummy) és a fogyasztás logaritmusának termékcsoporttal vett interakciója. (2) Ezen a modellen pedig már ellenőrizhetőek az előzetesen együtthatók összegére feltett megszorítások Wald-féle F-próbával. A 2. egyenletben ismertetett



2. ábra. A becült paraméterek alapján az egyes termékcsoportok fogyasztása a teljes fogyasztás függvényében



3. ábra. Az fogyasztás szintje és alkoholra fordított fogyasztási hányad megoszlása

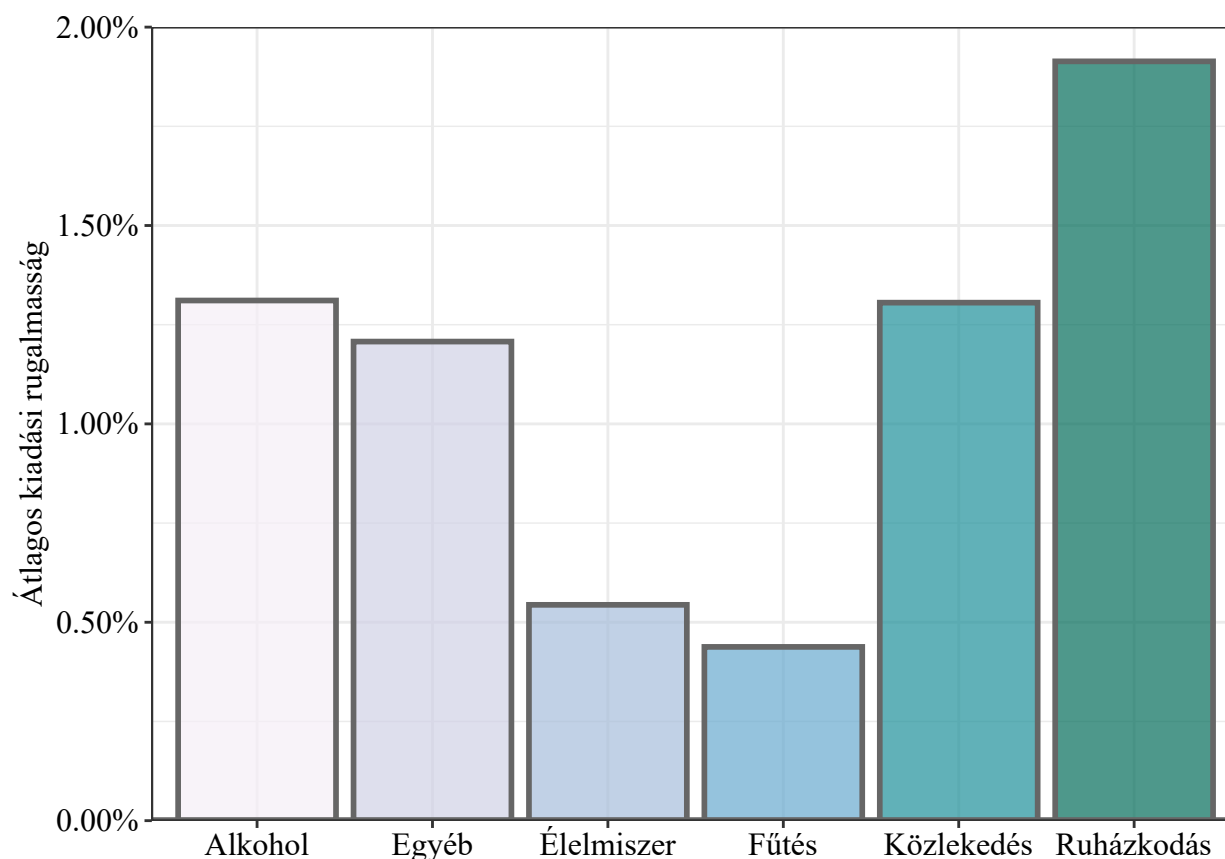
algebrai kapcsolat fennállásának nullhipotézisét, miszerint mindegyik együtttható összege 1 nem tudjuk elutasítani (F-próba p-értéke 49,47%). A 3. egyenletben látott  $H_0$ -t - miszerint a fogyasztás logaritmusának egyes termékcsoportokhoz becsült együttthatóinak összege 1 - szintén nem lehet elvetni (F-próba p-értéke 99,99%).

## Átlagos kiadási rugalmasságok

Az előzőekben bemutatott lineáris modellben a fogyasztás logaritmusához rendelt együtttható állandó volt, függetlenül attól, hogy mennyi az aktuális fogyasztás. Azonban itt a fogyasztáson belüli megoszlása a termékcsoportnak volt modellezve, nem a fogyasztásra fordított összeg. Érdekes megvizsgálni, hogy az egyes termékekre fordított összeg miként változik együtt a jövedelemmel. Ehhez az átlagos kiadási rugalmasságot ( $\ell$ ) választom megfelelő eszköznek, ami megmutatja, hogy  $j$ -edik termékre fordított összeg hány %-kal változik meg várhatóan c. p., ha 1%-kal megnő a fogyasztás. Ez az érték viszont rögzített  $\beta_j$  és  $\gamma$  mellett sem lesz konstans a fogyasztás mértékének függvényében. A számszerűsítéséhez kiszámítom minden mintában lévő fogyasztóra ( $i = 1, 2, \dots, 594$ ) a modellek alapján becsült kiadási rugalmasságot, és ezeknek az értékeknek veszem számtani átlagát mindegyik fogyasztó esetében. A paraméterbecslésekből és adatokból való levezetést a 4. egyenlet írja le.

$$\begin{aligned} \hat{w}_{0ji} &= \hat{\beta}_j + \hat{\gamma}_j \log(\text{cons}_i), \quad i = 1, 2, \dots, 594 \\ \hat{w}_{1ji} &= \hat{\beta}_j + \hat{\gamma}_j \log(\text{cons}_i \times 1,01) \\ \ell_j &= \frac{\sum_{i=1}^{594} \frac{\hat{w}_{1ji} \times 1,01 \text{cons}_i - \hat{w}_{0ji} \times \text{cons}_i}{\hat{w}_{0ji} \times \text{cons}_i}}{594} \end{aligned} \quad (4)$$

A 6 termékcsoporthoz becsült átlagos kiadási rugalmasságot 4. ábra mutatja be. Mindegyik esetben 0-nál nagyobb értéket kaptunk, tehát mindegyik esetben **normál javakról** van szó, ahol a kiadás mértékének függvényében növekszik az egyes termékekre kiadott összeg.




4. ábra. Regressziós modellek alapján becsült átlagos kiadási rugalmasság termékcsoportonként

## A modell bővítése

A 3. ábra alapján belátható, hogy még a fogyasztás logaritmizálása után is felmerülhet, hogy a magyarázóváltozónak kvadratikus alakját is felhasználjuk a regresszióban. Dolgozatomban ezt a kiterjesztést a ruházkodás és az üzemanyag fogyasztásra fókuszálva vizsgálom el<sup>2</sup>.

<sup>2</sup>Feladatleírás által megadott korlátozás



2. táblázat. A fűtés fogyasztáson belüli arányára becsült eredeti modell (I.) és a bővített modell (II.)

Változó	I. modell	II. modell
Konstans	0,3095***	0,6459***
log(cons)	-0,0486***	-0,1974***
log(cons) <sup>2</sup>	NA	0,0163**

*Jelölések:*

\* 10%-on szignifikáns

\*\* 5%-on szignifikáns


\*\*\* 1%-on szignifikáns

1. táblázat: A ruházzkodás fogyasztáson belüli arányára becsült eredeti modell (I.) és a bővített modell (II.)

Változó	I. modell	II. modell
Konstans	-0,2705***	-0,5963*
log(cons)	0,0843***	0,2284*
log(cons) <sup>2</sup>	NA	-0,0158

3. táblázat: Átlagos parciális hatás az eredeti modellben (I. modell) és a kvadratikus komponenssel bővített modellben (II. modell)

Változó	I. modell	II. modell
Ruházzkodás	0,0843	0,0843
Fűtés	-0,0486	-0,0486





## R kódok

```

1  # SETUP -----
2
3  library(tidyverse)
4  library(granatlib) # my personal package: https://github.com/MarcellGranat/granatlib
5  theme_set(theme_granat())
6  dat <- rio::import('cons.xlsx') %>%
7    filter(NK == 1)
8
9  # Frequently used functions =====
10
11 f.pvalues <- function(x) {
12   case_when(
13     x <= .1 & x > .05 ~ '10%',
14     x <= .05 & x > .01 ~ '5%',
15     x < .01 ~ '1%',
16     T ~ '-'
17   )
18 }
19
20 f.products <- function(x) {
21   case_when(
22     x == 'WALC' ~ 'Alkohol',
23     x == 'WCLOTH' ~ 'Ruházkodás',
24     x == 'WFOOD' ~ 'Élelmiszer',
25     x == 'WFUEL' ~ 'Fűtés',
26     x == 'WOTHER' ~ 'Egyéb',
27     x == 'WTRANS' ~ 'Közlekedés'
28   )
29 }
30 # PART I. -----
31
32 # a =====
33
34 ### Statistical significance #####
35 dat %>%
36   {select(., CONS, which(str_detect(names(.), 'W')))} %>%
37   pivot_longer(-1, names_to = 'x', values_to = 'w') %>%
38   mutate(CONS = log(CONS)) %>%
39   group_by(x) %>%
40   do(broom::tidy(lm(w ~ CONS, .), conf.int = T, conf.level = 0.99)) %>%
41   filter(term == 'CONS') %>%
42   mutate(x = f.products(x)) %>%
43   ggplot +
44   geom_col(aes(x, estimate), fill = 'aquamarine4', color = 'grey40', size = 1) +
45   geom_errorbar(aes(x, ymin = conf.low, ymax = conf.high,
46                     color = "Konfidencia intervallum"),
47                 width = 0.4, alpha = 0.9, size = 1.2) +
48   geom_hline(yintercept = 0, color = 'grey40', size = 1) +
49   labs(x = NULL, y = 'Becsült koefficiens', color = NULL) +
50   scale_color_manual(values = c('red3'))
51

```

```

52 ### Economic significance #####
53 dat %>%
54 {select(., which(str_detect(names(.), 'W')))} %>%
55 apply(2, function(y) lm(data = data.frame(y, x = dat$CONS),
56                          formula = y ~ I(log(x)))) %>%
57 lapply(function(mod) predict.lm(object = mod,
58                                newdata = data.frame(x = seq(from = min(dat$CONS),
59                                                            to = max(dat$CONS),
60                                                            length.out = 100)))) %>%
61 lapply(function(y) data.frame(y)) %>%
62 reduce(cbind) %>%
63 set_names(names(dat)[which(str_detect(names(dat), 'W'))]) %>%
64 mutate(cons = seq(from = min(dat$CONS), to = max(dat$CONS),
65                   length.out = 100)) %>%
66 pivot_longer(-cons) %>%
67 mutate(name = f.products(name)) %>%
68 {
69   ggpubr::ggarrange(
70     ggplot(.) +
71       geom_area(aes(x = cons, y = value, fill = name), position = 'stack',
72                 color = 'black', size = .4) +
73       scale_x_continuous(expand = c(0, 0)) +
74       scale_y_continuous(expand = c(0, 0), labels = scales::percent) +
75       scale_fill_brewer(palette = 10) +
76       labs(x = 'Fogyasztás nagysága', y = 'Fogyasztáson belüli arány', fill = NULL),
77     mutate(., value = value*cons) %>%
78     ggplot +
79       geom_area(aes(x = cons, y = value, fill = name), position = 'stack',
80                 color = 'black', size = .4) +
81       scale_x_continuous(expand = c(0, 0)) +
82       scale_y_continuous(expand = c(0, 0)) +
83       scale_fill_brewer(palette = 10) +
84       labs(x = 'Fogyasztás nagysága', y = 'Fogyasztás pénzben', fill = NULL),
85     nrow = 1, common.legend = T, legend = 'bottom', labels = c('a', 'b'))
86   }
87 }
88
89 dat %>%
90 select(CONS, WALC) %>%
91 ggplot(aes(CONS, WALC)) +
92 geom_point(shape = 21, mapping = aes(CONS, WALC, fill = 'Valós értékek'),
93           color = 'black') +
94 geom_smooth(mapping = aes(CONS, WALC, color = 'Trend'), size = 1.5,
95           fill = 'midnightblue', alpha = .3) +
96 scale_y_continuous(labels = scales::percent) +
97 scale_x_log10(expand = c(0, 0)) +
98 scale_color_manual(values = c('midnightblue')) +
99 scale_fill_manual(values = c('coral')) +
100 labs(x = 'Fogyasztás (logaritmikus skála)', y = expression(W[Alkohol]),
101      color = NULL, fill = NULL) +
102 theme(legend.box = 'horizontal')
103
104 # c =====

```

```

105
106 dat %>%
107   select(CONS, which(str_detect(names(.), 'W')))) %>%
108   pivot_longer(-1) %>%
109   lm(formula = value ~ name + I(log(CONS)):name) %T>%
110   {
111     restrict <- paste(paste(coef(.) %>% names %>% tail(6), collapse = ' + '), '= 0')
112     car::linearHypothesis(model = ., restrict) %>% print
113   } %>%
114   {
115     restrict <- paste(paste(coef(.) %>% names, collapse = ' + '), '= 1')
116     car::linearHypothesis(model = ., restrict)
117   }
118
119 # b =====
120 #
121 ### Mean elasticity to CONS #####
122 dat %>%
123   {select(., which(str_detect(names(.), 'W')))} %>%
124   apply(2, function(y) lm(data.frame(y, CONS = dat$CONS), formula = y ~ log(CONS))) %>%
125   lapply(function(mod) {
126     y0 <- predict.lm(object = mod, newdata = dat)*dat$CONS
127     y1 <- predict.lm(object = mod, newdata = mutate(dat, CONS = CONS*1.01))*dat$CONS*1.01
128     (y1-y0)/y0
129   })
130 ) %>%
131 supply(mean) %>%
132 {data.frame(x = f.products(names(.)), ell = .)} %>%
133 ggplot() + geom_col(aes(x, ell, fill = x), color = 'grey40',
134                      alpha = .7, size = 1) +
135   geom_hline(yintercept = 0, color = 'grey40', size = 1.2) +
136   scale_y_continuous(labels = scales::percent, limits = c(0, .02), expand = c(0, 0)) +
137   labs(x = NULL, y = 'Átlagos kiadási rugalmasság', fill = NULL) +
138   scale_fill_brewer(palette = 10, guide = F)
139 # PART II. -----
140 dat %>%
141   transmute(CONS = log(CONS), WCLOTH, WFUEL) %>% # neptun: AYCOPF
142   pivot_longer(-1) %>%
143   mutate(
144     name = f.products(name)
145   ) %>%
146   ggplot(aes(CONS, value)) +
147   geom_point(shape = 21, fill = 'coral') +
148   geom_smooth(method = 'lm', formula = "y~x",
149              aes(color = 'y~x'), se = F, size = 2) +
150   geom_smooth(method = 'lm', formula = "y~poly(x, 2)", aes(color = 'y~x+x^2'),
151              se = F, size = 2) +
152   facet_wrap(~name, scales = 'free_y') +
153   labs(y = expression(W[x]), x = expression(log(CONS)), color = NULL) +
154   scale_color_viridis_d()
155
156 dat %>%
157   {mod1 <- lm(., formula = WCLOTH ~ I(log(CONS)))
158     mod2 <- lm(., formula = WCLOTH ~ I(log(CONS)) + I(log(CONS)^2))

```

```

159   merge(broom::tidy(mod1), broom::tidy(mod2), by = 'term', all = T)} %>%
160   select(1, 2, 5, 6, 9) %>%
161   mutate(
162     p.value.x = case_when(
163       p.value.x <= .1 & p.value.x > .05 ~ '*',
164       p.value.x <= .05 & p.value.x > .01 ~ '**',
165       p.value.x <= .01 ~ '***',
166       T ~ ''
167     ),
168     p.value.y = case_when(
169       p.value.y <= .1 & p.value.y > .05 ~ '*',
170       p.value.y <= .05 & p.value.y > .01 ~ '**',
171       p.value.y <= .01 ~ '***',
172       T ~ ''
173     )
174   ) %>%
175   transmute(term = (c('Konstans', 'log(cons)', 'log(cons)^2')),
176             mod1 = str_c(format(estimate.x, decimal.mark = ',', digits = 3), p.value.x),
177             mod2 = str_c(format(estimate.y, decimal.mark = ',', digits = 3), p.value.y)
178           ) %>%
179   knitr::kable(col.names = c('Változó', 'I. modell', 'II. modell'),
180               format.args = list(decimal.mark = ','), digits = 2,
181               caption = 'A ruházatkódás fogyasztáson belüli
182               arányára becsült eredeti modell (I.) és a bővített modell (II.)',
183               align = c('l', 'c', 'c')) %>%
184   kableExtra::footnote(symbol = c('10%-on szignifikáns', '5%-on szignifikáns',
185                                   '1%-on szignifikáns'),
186                        symbol_manual = c('*', '**', '***'),
187                        symbol_title = 'Jelölések:') # TODO footnote
188 dat %>%
189   {mod1 <- lm(., formula = WFUEL ~ I(log(CONS)))
190   mod2 <- lm(., formula = WFUEL ~ I(log(CONS)) + I(log(CONS)^2))
191   merge(broom::tidy(mod1), broom::tidy(mod2), by = 'term', all = T)} %>%
192   select(1, 2, 5, 6, 9) %>%
193   mutate(
194     p.value.x = case_when(
195       p.value.x <= .1 & p.value.x > .05 ~ '*',
196       p.value.x <= .05 & p.value.x > .01 ~ '**',
197       p.value.x <= .01 ~ '***',
198       T ~ ''
199     ),
200     p.value.y = case_when(
201       p.value.y <= .1 & p.value.y > .05 ~ '*',
202       p.value.y <= .05 & p.value.y > .01 ~ '**',
203       p.value.y <= .01 ~ '***',
204       T ~ ''
205     )
206   ) %>%
207   transmute(term = (c('Konstans', 'log(cons)', 'log(cons)^2')),
208             mod1 = str_c(format(estimate.x, decimal.mark = ',', digits = 3), p.value.x),
209             mod2 = str_c(format(estimate.y, decimal.mark = ',', digits = 3), p.value.y)
210           ) %>%
211   knitr::kable(col.names = c('Változó', 'I. modell', 'II. modell'),

```

```

212     format.args = list(decimal.mark = ','), digits = 2,
213     format = 'latex',
214     caption = 'A fűtés fogyasztáson belüli
215     arányára becsült eredeti modell (I.) és a bővített modell (II.)',
216     align = c('l', 'c', 'c')) %>%
217 kableExtra::footnote(symbol = c('10%-on szignifikáns', '5%-on szignifikáns',
218     '1%-on szignifikáns'),
219     symbol_manual = c('*', '**', '***'),
220     symbol_title = 'Jelölések:')
221 # PART III. -----
222
223 dat %>%
224   select(WCLOTH, WFUEL) %>%
225   apply(2, function(y) {
226     mod1 <- lm(data = data.frame(y = y, x = log(dat$CONS)), formula = y ~ x)
227     coef1 <- mod1$coeff['x']
228     mod2 <- lm(data = data.frame(y = y, x = log(dat$CONS)), formula = y ~ x + x^2)
229     coef2 <- mean(predict.lm(newdata = data.frame(x = log(dat$CONS) + 1), object = mod2)
230       - mod2$fitted)
231     data.frame(coef1, coef2)
232   })
233 ) %>%
234   reduce(rbind) %>%
235   transmute(var = c('Ruházkodás', 'Fűtés'), coef1, coef2) %>%
236   set_names('Változó', 'I. modell', 'II. modell') %>%
237   knitr::kable(
238     caption = 'Átlagos parciális hatás az eredeti modellben (I. modell) és a
239     kvadratis komponenssel bővített modellben (II. modell)',
240     align = c('l', 'c', 'c'),
241     format.args = list(digits = 3, decimal.mark = ',')
242   )
243 # PART V. -----
244
245 dat %>%
246   mutate(
247     class = cut(INCOME, breaks = quantile(dat$INCOME, probs = (0:3)/3),
248       include.lowest = T),
249     cons_food = CONS*WFOOD,
250     help = cons_food*.1/INCOME
251   ) %>%
252   group_by(class) %>%
253   summarise(help = mean(help)) %>%
254   ggplot(aes(factor(class), help)) +
255   geom_col(fill = 'aquamarine4', color = 'grey40', size = 1) +
256   geom_hline(yintercept = 0, color = 'grey40', size = 1.2) +
257   labs(x = 'Jövedelem kategória', y = 'Jövedelem arányos haszon') +
258   scale_y_continuous(limits = c(0, .04), expand = c(0, 0))

```